02_integration_annotation 重构设计

日期：2026-03-10 **版本**：v3.0（重构版） **项目**：胆囊癌 PNI 单细胞分析（PNI SC） **状态**：已批准，待实现

背景与目标

在 `01_qc_preprocess.ipynb` 完成逐样本 QC 后，本 notebook 承担从 QC-clean 数据出发的完整"整合 → 诊断 → 大类注释 → 谱系精细注释"全流程。

核心设计原则：

- **半自动化注释**：自动出图，人工判断，手动填写 cluster→亚型映射，再由代码应用
- **所有谱系统一模式**：相同的4-cell结构，降低维护成本
- **小样本保护**：3个患者的数据需要在每步可视化中暴露患者贡献，避免患者特异性假象

Notebook 结构总览

```
Section 0:  配置中心 & 共用工具函数
Section 1:  数据载入与合并
Section 2:  预处理 & Harmony 整合 & 细胞周期评分
Section 3:  整合效果诊断（矫正前后对比 + 患者贡献）
Section 4:  全局聚类 & 大类注释 → 中间检查点保存
──────────────── 谱系精细注释（统一模式）────────────────
Section 5:  Epithelial（恶性亚型细化）
Section 6:  Myeloid（TAM/DC/Neutrophil）
Section 7:  Lymphoid（T/NK细胞）
Section 8:  Fibroblast / CAF
Section 9:  Neural / Schwann
Section 10: Endothelial
──────────────────────────────────────────────────────────
Section 11: 汇总注释回写 & 最终导出
```

各 Section 详细设计

Section 0 — 配置 & 共用工具函数

Config 类（集中管理所有路径与超参数）：

- 路径：`QC_INDEX`、`OUT_DIR`、`FIG_DIR`、`TAB_DIR`
- 参数：`RANDOM_SEED=2026`、`N_HVG=3000`、`N_PCS=30`、`RESOLUTION_MAIN=0.6`、`RESOLUTION_SUBSET=0.4`

共用工具函数：

函数	说明

函数	说明
`plot_markers(adata, marker_dict, title)`	dotplot + violin + feature UMAP 三联图
`plot_patient_contribution(adata, cluster_key)`	堆叠柱状图，X=cluster，Y=比例，色=patient_id
`apply_annotation(adata, mapping, col_name)`	将 cluster→亚型 映射写入 obs
`run_subset_pipeline(adata, batch_key, resolution)`	HVG→PCA→Harmony→Neighbors→UMAP→Leiden
`make_annotation_template(adata, cluster_key)`	自动生成 `{cluster_id: ""}` 模板并打印

Section 1 — 数据载入与合并

```
读取 results/tables/qc/qc_clean_object_index.tsv
→ 逐样本载入 h5ad，附加元数据列：
    sample_id / patient_id / tissue_type / pni_level
→ sc.concat(join="outer", fill_value=0, index_unique="_")
→ 保存 adata.layers["counts"]（原始 count 备份）
→ 打印：总细胞数、各样本细胞数分布
```

Section 2 — 预处理 & Harmony 整合 & 细胞周期评分

```
normalize_total(target_sum=1e4) → log1p
→ HVG 筛选（n_top_genes=3000, flavor="seurat"）
→ PCA（n_comps=30, use_highly_variable=True）
→ 细胞周期评分：
    sc.tl.score_genes_cell_cycle(adata, s_genes, g2m_genes)
    （用于后续判断是否需要回归，此处不自动回归，人工决定）
→ Harmony 整合（key=sample_id）→ X_pca_harmony
→ Neighbors（use_rep="X_pca_harmony"）→ UMAP → Leiden(0.6)
```

注意：细胞周期评分结果将在 Section 3 中叠加可视化，由分析者判断增殖驱动的cluster是否需要特殊处理。

Section 3 — 整合效果诊断

矫正前后并排 UMAP（4图）：

1. `X_pca` colored by `sample_id`（矫正前）
2. `X_pca_harmony` colored by `sample_id`（矫正后）
3. colored by `patient_id`
4. colored by `tissue_type`

细胞周期叠加 UMAP：

- colored by `phase`（G1/S/G2M）
- 判断是否存在增殖驱动的大型cluster

患者贡献柱状图：

- `plot_patient_contribution(adata, "leiden")`
- 识别患者特异性cluster（>80%来自单个患者 → 注释时标记为`patient_specific`）

Section 4 — 全局聚类 & 大类注释

```
基于 marker 评分的自动大类注释（沿用 safe_score_genes + annotate_by_score 逻辑）
覆盖谱系：Epithelial / Myeloid / Lymphoid / Fibroblast / Neural / Endothelial

→ UMAP：colored by leiden / cell_class_auto / pni_level
→ 上皮恶性初筛（malignancy_v1）
→ 按大类切分 subset，存入 dict：
    subsets = {"Epithelial": ..., "Myeloid": ..., ...}

—— 中间检查点保存 ——
adata.write_h5ad(OUT_DIR / "integrated_global.h5ad")
（后续谱系注释阶段重跑时可从此处载入，无需重跑 Harmony）
```

Sections 5–10 — 谱系精细注释（统一4-cell模式）

每个谱系的结构完全一致：

```
# ── [Cell A] 载入 + 谱系内再整合 ──────────────────────────
sub = run_subset_pipeline(subsets["Myeloid"], batch_key="sample_id",
                          resolution=Config.RESOLUTION_SUBSET)

MYELOID_MARKERS = {
    "Macrophage_M1":  ["IL1B", "TNF", "CXCL10", "CD80", "HLA-DRA"],
    "Macrophage_M2":  ["CD163", "MRC1", "TGFB1", "CCL18", "FOLR2"],
    "TAM_SPP1":       ["SPP1", "APOE", "C1QA", "TREM2"],
    "cDC1":           ["CLEC9A", "CADM1", "XCR1"],
    "cDC2":           ["ITGAX", "CD1C", "FCER1A", "CLEC10A"],
    "pDC":            ["LILRA4", "IRF7", "CLEC4C"],
    "Neutrophil":     ["S100A8", "S100A9", "FCGR3B", "CSF3R"],
    "Monocyte":       ["CD14", "LYZ", "S100A4", "CCR2"],
}

# ── [Cell B] 自动出图 ──────────────────────────────────────
plot_markers(sub, MYELOID_MARKERS, title="Myeloid Markers")
plot_patient_contribution(sub, "leiden")
# ↑ 在此查看 dotplot / violin / feature UMAP + 患者贡献图
```

```
# ── [Cell C] ⬇ 人工填写映射 ─── 暂停点 ──────────────────
make_annotation_template(sub, "leiden")   # 自动打印模板，复制后填写
cluster_annotation = {
    "0": "",   # ← 根据上图填写亚型名称
    "1": "",
    # ...
}

# ── [Cell D] 应用注释 + 保存 + 汇总图 ────────────────────
sub = apply_annotation(sub, cluster_annotation, "cell_subtype")
sc.pl.umap(sub, color=["cell_subtype", "patient_id", "pni_level"])
sub.write_h5ad(Config.OUT_DIR / "subset_myeloid_annotated.h5ad")
```

各谱系的 marker 字典预设范围：

Section	谱系	预期亚型
5	Epithelial	likely_malignant / normal_biliary / malignant_EMT / malignant_PNI
6	Myeloid	TAM_M1 / TAM_M2 / TAM_SPP1 / cDC1 / cDC2 / pDC / Neutrophil / Monocyte
7	Lymphoid	CD8_effector / CD8_exhausted / CD4_Tconv / Treg / NK / NKT / B_cell
8	Fibroblast	myoCAF / iCAF / apCAF / vCAF / normal_fibroblast
9	Neural/Schwann	Schwann_repair / Schwann_promyelinating / Schwann_PNI / neural_progenitor
10	Endothelial	normal_EC / tumor_EC / tip_EC

Section 11 — 汇总回写 & 最终导出

```
将各谱系 cell_subtype 注释合并回主 adata.obs["cell_subtype"]
→ 双层 UMAP：cell_class_auto（大类）+ cell_subtype（亚型）
→ 各谱系细胞数 & 亚型分布汇总表（per sample / per patient）
→ PNI level × cell_subtype 组成比例热图
→ 保存 integrated_final_annotated_v2.h5ad
```

关键设计决策

决策	选择	理由
人工介入方式	Notebook 分段执行，手动填写字典	最灵活，无额外依赖
Marker 来源	各谱系在 notebook 内维护独立字典	方便迭代修改
批次矫正	Harmony（每级均执行）	全局和谱系内均需要
细胞周期	评分但不自动回归	保留人工判断空间

决策	选择	理由
患者贡献	每个谱系必出柱状图	3患者数据的必要保护
中间保存	Section 4 后强制保存	避免重跑耗时整合步骤
内皮细胞	加入为 Section 10，轻量注释	TME完整性，轻量处理

输出文件清单

```
results/intermediate/integration/
├── integrated_global.h5ad              # Section 4 检查点
├── subset_epithelial_annotated.h5ad
├── subset_myeloid_annotated.h5ad
├── subset_lymphoid_annotated.h5ad
├── subset_fibroblast_annotated.h5ad
├── subset_neural_annotated.h5ad
├── subset_endothelial_annotated.h5ad
└── integrated_final_annotated_v2.h5ad  # 最终主对象

results/figures/integration/
├── harmony_before_after_umap.png
├── cell_cycle_umap.png
├── patient_contribution_global.png
├── global_umap_annotation.png
└── subset_<lineage>_markers.png × 6

results/tables/integration/
├── lineage_summary.tsv
└── celltype_composition_per_sample.tsv
```

依赖环境

`.conda` 环境需确认安装：

- `harmonypy`、`leidenalg`、`igraph`（整合必需）
- `scanpy >= 1.9`（`score_genes_cell_cycle` 内置）